Scrapowanie wakacje.pl oraz przetwarzanie tekstu

Spis treści

Wprowadzenie

Projekt obejmuje stworzenie aplikacji, która analizuje opinie dotyczące różnych hoteli ze strony wakacje.pl. Opracowano również narzędzia do przetwarzania tekstu, takie jak tokenizacja, lematyzacja, usuwanie stopwords oraz analizę częstości słów. Poniżej przedstawiono skrócony opis głównych komponentów projektu.

Sprawozdanie

Cele i wymagania

Celem projektu jest stworzenie systemu, który pozwala na analizę opinii o hotelach zebranej z witryny wakacje.pl. System ma za zadanie zbierać dane z różnych hoteli, przetwarzać je, a następnie generować statystyki i wizualizacje dotyczące częstości występowania słów oraz ogólnej struktury opinii. Algorytm ma za zadanie przeprowadzić poniższe operacje:

1. Utworzenie korpusu językowego z pobranych tekstów - korpus językowy to zbiór tekstów używany do analizy języka naturalnego. Może zawierać różnorodne teksty, takie jak artykuły, książki, czy rozmowy, służące do badania struktury językowej, słownictwa, czy innych właściwości języka.

2. Tokenizacja - proces podziału tekstu na pojedyncze jednostki, zwane tokenami. Tokeny mogą reprezentować pojedyncze słowa lub inne fragmenty tekstu, takie jak zdania. Tokenizacja jest często pierwszym krokiem w analizie tekstu.

3. Lematyzacja - proces zamiany słów na ich lematy, czyli formy podstawowe. Lemat to forma słowa, która reprezentuje jego podstawowy rdzeń. Ten proces pomaga w redukcji słów do ich podstawowej postaci, co ułatwia analizę tekstu.

4. Stemming - proces usuwania końcówek słów, aby uzyskać ich formę podstawową (tzw. rdzeń). Jest to bardziej agresywne podejście niż lematyzacja, ponieważ nie zawsze prowadzi do poprawnych form podstawowych.

5. Usuwanie słów z listy stopu - lista stopu zawiera słowa, które są często używane w języku, ale zazwyczaj nie niosą istotnego znaczenia, takie jak przyimki, spójniki, zaimki, etc. Usuwanie tych słów z tekstu pomaga skoncentrować się na bardziej istotnych aspektach analizy.

6. Analiza statystyczna oraz wizualizacja - analiza statystyczna obejmuje wykorzystanie metod statystycznych do zrozumienia i wyciągania wniosków z danych tekstowych. Wizualizacja danych tekstowych może obejmować tworzenie wykresów, diagramów, czy innych form graficznych prezentujących informacje zawarte w tekście.

7. Wektoryzacja - roces reprezentowania tekstu jako wektora liczb. W tekście każde słowo lub fragment tekstu jest przypisywane do odpowiedniego wektora numerycznego. Ten proces jest kluczowy w wielu technikach analizy tekstu, takich jak modelowanie tematów czy klasyfikacja dokumentów.

Wykorzystane narzędzia

1. Język programowania Python Python to język programowania wysokiego poziomu ogólnego przeznaczenia, o rozbudowanym pakiecie bibliotek standardowych, którego ideą przewodnią jest czytelność i klarowność kodu źródłowego. Jego składnia cechuje się przejrzystością i zwięzłością.

2. Biblioteka BeautifulSoup jest wykorzystywana do parsowania i analizy strony internetowej. Pozwala na wygodne ekstrahowanie danych z kodu HTML, co jest istotne podczas scrappingu informacji z witryny wakacje.pl.

3. Biblioteka spaCy została użyta do przetwarzania języka naturalnego. Zawiera modele do analizy gramatycznej, tokenizacji oraz lematyzacji tekstu w języku polskim. Umożliwia efektywne przetwarzanie dużych ilości danych tekstowych.

4. Biblioteka scikit-learn jest używana do analizy tekstu, zwłaszcza do wektorowania tekstu i tworzenia macierzy cech. Wykorzystuje się w niej moduły takie jak CountVectorizer oraz TfidfVectorizer do konwersji zbioru dokumentów tekstowych na reprezentację liczbową.

5. Biblioteka nltk dostarcza narzędzi do przetwarzania języka naturalnego, takich jak tokenizacja czy stemming. W projekcie użyto stemmera PorterStemmer do przekształcania słów na ich podstawową formę.

6. Biblioteka wordcloud została użyta do generowania chmur słów (word clouds) wizualizujących najczęściej występujące słowa w analizowanym tekście.

7. Biblioteka matplotlib jest wykorzystywana do generowania różnych wykresów, w tym słupkowych, co pozwala na wizualizację wyników analizy tekstu.

8. Opisy funkcji (docstrings) są wygenerowane przy użyciu dodatku do VSC opartego na AI.

Zobrazowanie działania aplikacji

1. Scraper wakacje.pl

Poprzez uruchomienie kodu z pliku scrap_data.py aplikacja przy użyciu pakietu bs4 pobiera opienie o chotelach z portalu wakacje.pl. Targetem scrapera jest strona https://www.wakacje.pl/hotele/ z której dynamicznie pobierane są linki do 10 hoteli uznawanych przez platformę za najczęściej oceniane. Następnie skrypt iteruje przez wszystkie 10 hoteli zapisując opinie o nich do pliku 1_opinions.json. Skrypt uwzględnia

paginację występującą na portalu i iteruje przez wszystkie dostępne strony z opiniami (na jednej stronie znajduje się max 20 opinie).

2. Analiza języka

Po uruchomieniu pliku main.py program tworzy korpus językowy łącząc wszystkie opinie w jednen zbiorczy tekst i etap ten zapisywany jest do pliku 2_corpus.txt. Następnmie przeprowadzana jest tokenizacja czyli wydzielane są pojedyńcze słowa i zapisywane do pliku 3_tokenized.txt w formacie 1 linia = 1 token (słowo). Kolejnymi etapami są przeprowadzone kolejno lemantyzacja czyli zamiana słów na formy podstawowe oraz steamming - usuwanie końcówek słów. Po zakończeniu powyższych procesów, dane po każdym etapie zapisywane są odpowiednio do plików 4_lemmantized.txt oraz 5_stemmed.txt. Do przeprowadzenia obu operacji wykorzystywana jest biblioteka spacy z zaimportowanymi paczkami do języka polskiego. Idąc dalej, skrypt tworzy plik 6_filtered.txt, który zawiera tokeny z usuniętymi słowami, które powtarzają się zbyt często lub są zbędnę dla analizy tekstu.

3. Wizualizacja

Tokeny poddane lemantyzacji i filtrowaniu są przekazywane do funkcji która analizuje częstotliwość występowania poszczególnych słów w oponiach gości hotelowych.

W wyniku działania aplikacji, w konsoli wyświetlana jest liczba wszystkich słów oraz unikalnych, a następnie generowane są 2 pliki PNG, które są zamieszczone poniżej. Jeden z nich pokazuje częstotliwość występowania słów w formie wykresu typu wordcloud, druga zaś to tradycyjny wykres kolumnowy top 0,3% najpopularniejszych słów.

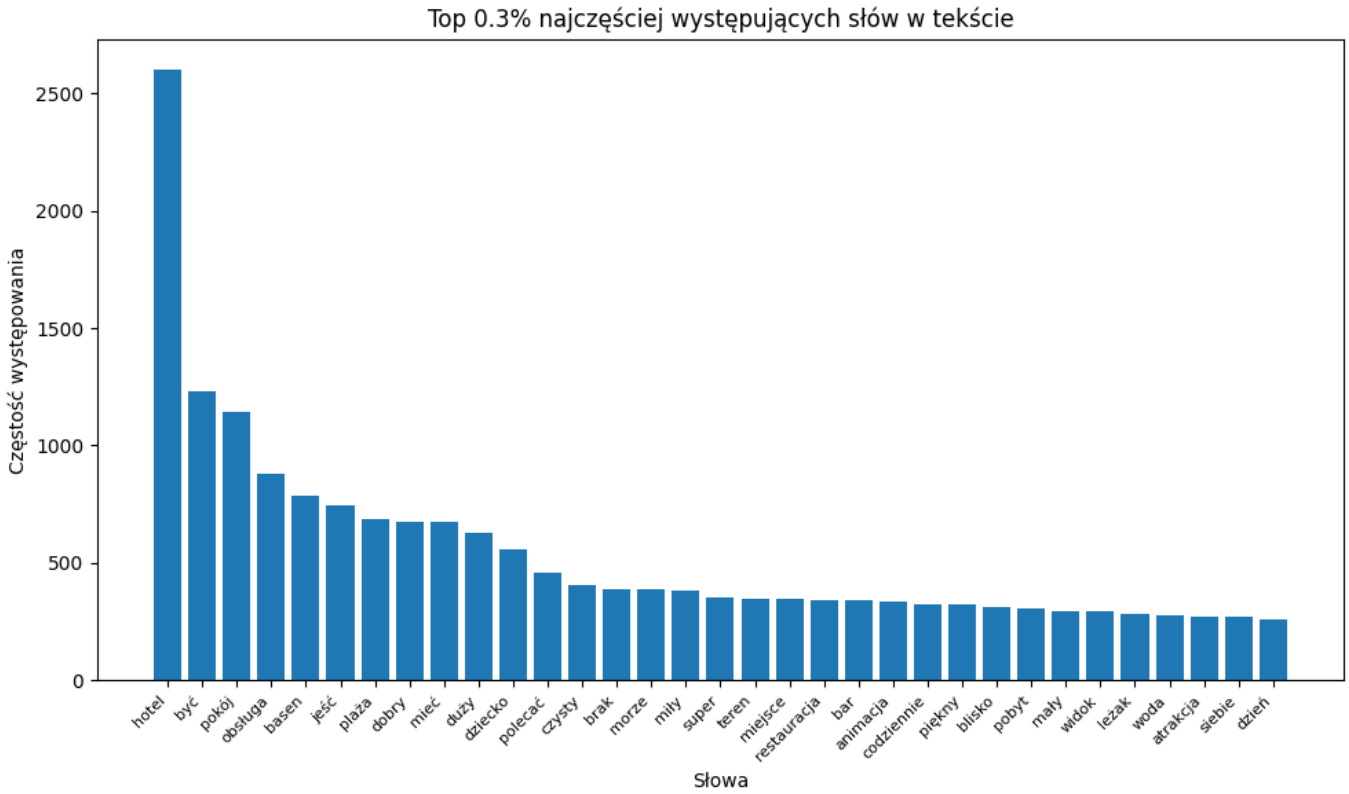

4. Wektoryzacja

Na koniec przeprowadzana jest wektoryzacja przy użyciu pakietu sklearn i importowanej funkcji CoutVectorized, a wynik zapisywany jest do pliku 8_vectorized.txt

Do wszystkich wyżej wyminionych etapów, przykładowe dane zostały zappisane w folderze example_resultes z odpowiadającymi nazwami poszczególnych plików.

Podsumowanie

Projekt skupia się na analizie opinii dotyczących hoteli zebranych z witryny wakacje.pl. Główne cele projektu obejmują skuteczne pobieranie danych z witryny, przetwarzanie języka naturalnego oraz generowanie

statystyk i wizualizacji.

Scraper, oparty na bibliotekach requests i BeautifulSoup, zbiera opinie o hotelach ze strony wakacje.pl, a następnie dane są przetwarzane przy użyciu narzędzi do analizy tekstu. Biblioteka spaCy wspomaga tokenizację, lematyzację i usuwanie stopwords, natomiast scikit-learn umożliwia wektorowanie tekstu i analizę częstości słów. Dodatkowo, nltk dostarcza stemmera do przetwarzania słów, a biblioteki wordcloud i matplotlib pomagają w wizualizacji wyników.

Dokumentacja techniczna

Instalacja

1. Pobierz repozytorium z kodem i otwórz folder z projektem przy użyciu dowolnego IDE (na przykład Visual Studio Code).

2. Utwórz wirtualne środowisko i aktywuj je.

```
# Utworzenie środkowiska wirtualnego
python -m venv /path/to/new/virtual/environment
# Aktywacja środkowiska wirtualnego
.\env\Scripts\activate
```

3. Używając menedżera pakietów pip, zainstaluj wymagane biblioteki.

```
pip install -r requirements.txt
```

Uruchomienie aplikacji

1. Aktywuj środowisko wirtualne.

```
# Aktywacja środkowiska wirtualnego
.\env\Scripts\activate
```

2. Przejdź do folderu, który zawiera plik main.py.
3. Uruchom scraper lub przetwarzanie tekstu używając poniższego polecenia :

```
python3 main.py
python3 scrap_data.py
```